TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Projeto em Business Intelligence e Analytics
Fase 2

Nome do estudante: Paulo Henrique Santo Silva

1. Métricas para o negócio proposto (KPIs):

- **Média de Preço de Abertura:** acompanha o comportamento médio dos ativos no início do pregão, auxiliando na identificação de tendências de mercado.

- **Média de Preço de Fechamento:** mede o valor médio dos ativos ao final do pregão, permitindo avaliar o desempenho das ações ao longo do período.

- **Máximo de Fechamento:** identifica o maior valor de fechamento registrado, servindo como referência para análise de desempenho e volatilidade.

- **Variação Mês a Mês (MoM):** monitora o crescimento ou queda percentual dos preços em relação ao mês anterior. No dashboard, observa-se uma variação de **-3,12%**.

- **Variação Ano a Ano (YoY):** avalia o desempenho comparando o período atual com o mesmo período do ano anterior. No dashboard, o indicador apresenta **11,56% de crescimento**.

- **Média de Volume Negociado:** acompanha a liquidez dos ativos e o interesse do mercado, permitindo identificar períodos de maior ou menor movimentação.

- **Ranking de Empresas por Média de Fechamento:** possibilita comparar o desempenho das empresas analisadas, destacando aquelas com maiores valores médios de fechamento.
- **RMSE do Modelo Preditivo:** mede o erro médio das previsões de preço de fechamento geradas pelos modelos de Machine Learning (Regressão Linear, Random Forest e XGBoost), indicando a precisão da camada de Analytics mês a mês.

Esses KPIs fornecem uma visão abrangente sobre desempenho, tendência de preços, liquidez e evolução dos ativos financeiros, apoiando a tomada de decisão de investidores e gestores.

2. Arquitetura da solução (ferramentas, pipeline com as fases, repositórios, dependências):

Descreva aqui a arquitetura da solução de BI implementada. Adicione diagramas com os componentes, descreva as ferramentas e plataformas selecionadas, repositórios e eventuais dependências.

A solução de Business Intelligence foi desenvolvida para coletar, processar, armazenar e visualizar dados do mercado financeiro da B3. A arquitetura segue uma abordagem em camadas, garantindo escalabilidade, organização e facilidade de manutenção.

Ferramentas Utilizadas

Camada	Ferramenta	Finalidade
Extração	Python + yFinance	Coleta de dados históricos das ações
Processamento	PySpark (Databricks) + Pandas	Limpeza, padronização e engenharia de atributos (camadas Bronze e Prata)
Armazenamento	Delta Lake + Arquivos CSV	Persistência das tabelas Bronze e Prata, e exportação dos CSVs para Power BI e Analytics
Versionamento	Git/GitHub	Controle de versão dos códigos
Visualização	Power BI	Construção dos dashboards e KPIs
Desenvolvimento	Jupyter Notebook / Databricks	Desenvolvimento e testes
Analytics / ML	scikit-learn + XGBoost	Modelagem preditiva do preço de fechamento (Regressão Linear, Random Forest e XGBoost)

Pipeline da Solução

1. Extração

Coleta automática dos preços das ações através da biblioteca yFinance.
Captura de informações como:

1. Data
2. Preço de abertura
3. Preço de fechamento
4. Máxima
5. Mínima
6. Volume negociado

2. Transformação

- Limpeza dos dados.
- Tratamento de valores nulos.
- Padronização e tradução de setor/indústria para português.
- Processamento dividido em duas camadas (arquitetura medallion): Bronze, com a ingestão bruta dos dados sem nenhuma regra de negócio, e Prata, com a limpeza, padronização e engenharia de atributos descritas a seguir.
- Criação de métricas derivadas.
- Cálculo de indicadores de desempenho.

3. Armazenamento

- Dados brutos persistidos em tabelas Delta na camada Bronze (bronze.cotacoes_b3 e bronze.cadastro_empresas_b3), sem nenhuma transformação de negócio.
- Dados tratados e enriquecidos persistidos em tabela Delta na camada Prata (prata.acoes_b3), já com os atributos derivados (variação diária, amplitude, retorno diário, média móvel de 20 dias).
- A partir da camada Prata, são exportados dois arquivos CSV: um formatado para o Power BI (separador **;** e decimal **,**, padrão pt-BR) e outro para a camada de Analytics (separador **,** e decimal **.**, padrão internacional, usado pelos modelos de Machine Learning).
- Estrutura em camadas (Bronze → Prata) preparada para evolução futura com uma camada Ouro, com agregações prontas para consumo direto em dashboards.

4. Consumo

- Importação dos dados no Power BI.
- Modelagem dimensional.
- Criação das medidas DAX.

5. Visualização

- Construção do dashboard interativo.
- Filtros por:
    - Segmento
    - Setor
    - Ano
    - Mês
    - Dia

6. Modelagem Preditiva (Analytics)

A partir do CSV de Analytics (camada Prata), foram treinados e comparados três modelos para prever o preço de fechamento do próximo pregão de cada ação:

- Regressão Linear, como modelo de referência (baseline).
- Random Forest, capturando relações não lineares entre as variáveis.
- XGBoost, modelo de gradient boosting, em geral o de melhor desempenho em dados tabulares.

A divisão entre treino e teste seguiu um corte temporal (80% dos pregões mais antigos para treino, 20% mais recentes para teste), evitando vazamento de dados do futuro. Os modelos foram avaliados pelas métricas MAE, RMSE e R^2, comparando os valores reais e previstos — resultado apresentado na 3ª visão do dashboard (Analytics e Modelo Preditivo).

3. Solução de BI:

Descreva a solução implementada. Link para o código fonte, dicionário de dados, dashboards e análises realizadas. No Link de acesso para o repositório na plataforma GitHub apresente:

A solução foi implementada em três notebooks, organizados em arquitetura de camadas (Bronze e Prata) e em uma camada de Analytics, todos documentados e versionados no repositório do GitHub indicado abaixo:

- **Finance_project_Bronze.ipynb** — extração via yFinance e persistência das tabelas brutas (bronze.cotacoes_b3 e bronze.cadastro_empresas_b3) em Delta Lake, sem nenhuma transformação de negócio.
- **Finance_project_Prata.ipynb** — limpeza, padronização (tradução de setor/indústria para português), engenharia de atributos, persistência da tabela curada (prata.acoes_b3), análise exploratória e exportação dos CSVs para Power BI e Analytics.
- **Finance_project_ML.ipynb** — treinamento e comparação de três modelos (Regressão Linear, Random Forest e XGBoost) para prever o preço de fechamento do dia seguinte, com split temporal e avaliação por MAE, RMSE e R^2.

Dicionário de Dados (tabela prata.acoes_b3)

Coluna	Descrição
data	Data do pregão
cd_empresa	Ticker da ação na B3 (ex.: PETR4.SA)
empresa	Nome completo da empresa
setor / segmento	Setor e indústria de atuação, traduzidos para português
abertura / maxima / minima / fechamento	Preços de abertura, máxima, mínima e fechamento do pregão (R$)
volume	Quantidade de ações negociadas no pregão
variacao_dia_pct	Variação percentual entre abertura e fechamento do dia
amplitude	Diferença entre máxima e mínima do dia
retorno_diario_pct	Variação percentual do fechamento em relação ao pregão anterior
media_movel_20d	Média móvel de 20 pregões do preço de fechamento
ano / mes / trimestre	Colunas de apoio para agregações temporais (usadas nos filtros do dashboard)

Os dashboards construídos no Power BI estão organizados em três visões, detalhadas na Apresentação Executiva da Fase 2: **Dashboard Executivo** (indicadores comparativos por empresa e trimestre), **Análise Financeira** (variações MoM/YoY, crescimento por empresa e comparação entre setores) e **Analytics e Modelo Preditivo** (real vs. previsto, erro do modelo e RMSE).

• Código fonte de preparação, coleta, limpeza, processamento de dados.
• Os Dashboards (visualizações) publicados na ferramenta escolhida.
• Documentação do código no GitHub.

https://github.com/PauloSilvaSH/Dados-financeiros-pucrs/tree/main